

Sensores que Detectam Mudanças Cognitivas em Motoristas Idosos.

1st Isabel Francine Mendes

Inatel

Matrícula: 56

Disciplina: IoT

Professor: Samuel Mafra

2nd Alexandre de Araujo

Inatel

Matrícula: 54

Disciplina: IoT

Professor: Samuel Mafra

I. INTRODUÇÃO

As redes veiculares estão emergindo como uma das áreas mais promissoras no campo da Internet das Coisas (IoT), fornecendo conectividade em tempo real entre veículos e a infraestrutura circundante. Esse desenvolvimento tecnológico tem possibilitado o estudo do comportamento de pessoas com Comprometimento Cognitivo Leve (MCI), uma condição que vem sendo amplamente pesquisada nas últimas décadas devido à sua influência na capacidade de direção. Esse comprometimento é visto, principalmente na população idosa. Segundo os relatórios da Organização Mundial da Saúde (OMS) e do Instituto Nacional de Saúde (NIH) o número geral de pessoas com 65 anos ou mais se expande rapidamente devido à melhoria dos cuidados de saúde e maior expectativa de vida. As previsões mostram que até 2050, a porcentagem da população mundial com 65 anos ou mais terá aumentado de 10% (em 2022) para 16% [2]. Na Tabela I, encontra-se uma análise aproximada da população global idosa (com 65 anos ou mais) por continente, baseada em dados de 2023 das Nações Unidas [1]. Os números da população são expressos em milhões.

Continentes	População idosa (65+)
Ásia	413 milhões
Europa	147 milhões
América do Norte	63 milhões
América Latina & Caribe	57 milhões
África	49 milhões
Oceania	7 milhões
Total	736 milhões

TABLE I
POPULAÇÃO IDOSA GLOBAL (65+)

Com isso em mente, analisamos duas pesquisas que têm como objetivo investigar o comportamento da direção de motoristas idosos através de sensores instalados em carros:

A. "Protocolo de estudo: Sensores no veículo para detectar mudanças na cognição de motoristas idosos"

O projeto de pesquisa intitulado [2], tem como objetivo explorar como o comportamento de direção em indivíduos com idade mais avançada pode ser influenciado por mudanças cognitivas precoces. Ao utilizar sistemas avançados de sensores

em veículos, os pesquisadores coletarão dados contínuos sobre padrões de direção e correlacionarão essas descobertas com avaliações cognitivas conduzidas a cada três meses ao longo de três anos (o projeto foi iniciado em 2023). Esta abordagem promete melhorar a compreensão da segurança ao dirigir e da saúde cognitiva em adultos idosos. O estudo vai monitorar várias mudanças cognitivas específicas em motoristas mais velhos, focando particularmente na transição do estado cognitivo não prejudicado para o comprometimento cognitivo leve (MCI). As mudanças cognitivas sendo examinadas incluem:

- Status cognitivo de base: Estabelecer as habilidades cognitivas iniciais dos participantes para comparar com avaliações futuras.
- Comportamentos de direção: Analisar como os padrões de direção podem mudar ao longo do tempo, o que pode indicar declínio cognitivo. Isso inclui métricas como tempo de reação, velocidade, posição lateral e distância de seguimento.
- Comportamentos cognitivos diferenciados: Avaliar comportamentos cognitivos subjacentes que podem não ser diretamente observáveis, mas podem ser inferidas do comportamento de direção.
- Agrupamentos de diagnóstico: Identificar mudanças que significam uma mudança do status não prejudicado para MCI ou demência em estágio inicial.

O estudo utiliza sensores no veículo para detectar essas mudanças capturando dados sobre o desempenho e os comportamentos de direção ao longo do tempo, permitindo uma avaliação abrangente do declínio cognitivo em motoristas mais velhos.

Como essa pesquisa é um protocolo e não há ainda resultados, escolhemos dar mais destaque para a segunda pesquisa.

B. "Detecção e análise de dados no veículo de motoristas idosos com comprometimento cognitivo leve"

Este estudo [3] se concentra em melhorar a experiência de dirigir para adultos mais velhos que já enfrentam desafios com comprometimento cognitivo leve (MCI), utilizando tecnologias avançadas de detecção e análise de dados para garantir a segurança e melhorar a mobilidade. Nas próximas seções serão destacadas informações sobre o comprometimento cognitivo, tecnologias para auxiliar e monitorar os indivíduos desse

estudo e também produtos semelhantes que já existem no mercado.

II. CONCEITOS

O comprometimento cognitivo leve pode afetar significativamente as habilidades de direção de várias maneiras:

- Declínio cognitivo: O MCI é caracterizado por mudanças sutis, mas perceptíveis, nas funções cognitivas, como memória, atenção e função executiva. Esses declínios podem prejudicar a capacidade de um indivíduo de processar informações rapidamente e tomar decisões seguras ao dirigir.
- Deficit de desempenho ao dirigir: Pesquisas indicam que adultos mais velhos com MCI podem apresentar quedas de desempenho ao dirigir em comparação com aqueles sem comprometimentos cognitivos. Isso pode se manifestar como dificuldades em navegar em situações complexas de trânsito, responder a mudanças repentinas no ambiente e manter velocidades adequadas.
- Aumento do risco de acidentes: Os desafios cognitivos associados ao MCI podem levar a um aumento do risco de acidentes. Os motoristas podem ter dificuldades com tarefas como avaliar distâncias, reconhecer sinais de trânsito e reagir adequadamente a perigos, o que pode comprometer sua segurança na estrada.
- Autorregulação do comportamento de direção: Motoristas mais velhos com MCI podem autorregular sua direção evitando situações desafiadoras, como dirigir à noite ou em trânsito pesado. Embora isso possa ser uma medida de proteção, também pode limitar sua mobilidade e independência.
- Alterações emocionais e comportamentais: O MCI também pode levar a mudanças emocionais, como aumento da ansiedade ou frustração ao dirigir, o que pode impactar ainda mais o desempenho ao dirigir e a tomada de decisões.

No geral, a combinação de declínio cognitivo, deficit de desempenho e fatores emocionais pode criar desafios significativos para adultos mais velhos com MCI, necessitando de sistemas de monitoramento e suporte para garantir sua segurança ao dirigir. Diante desse cenário, os principais objetivos da pesquisa, segundo os pesquisadores, incluem:

- Monitoramento do comportamento de direção: O estudo visa utilizar tecnologias de detecção no veículo para monitorar e analisar discretamente os comportamentos de direção de adultos mais velhos, particularmente aqueles que já exibem sinais precoces de declínio cognitivo.
- Detecção precoce de comprometimento cognitivo: Ao coletar e analisar dados relacionados a padrões de direção, a pesquisa busca identificar mudanças sutis no comportamento que podem indicar o início do MCI, permitindo intervenções oportunas.
- Aprimoramento da segurança nas estradas: O objetivo final é melhorar a segurança nas estradas para motoristas mais velhos desenvolvendo sistemas inteligentes

que podem fornecer feedback e assistência em tempo real, mitigando assim os riscos potenciais associados a comprometimentos cognitivos.

- Apoio à independência e mobilidade: A pesquisa visa prolongar a independência e a mobilidade de motoristas idosos integrando tecnologias avançadas de detecção que podem se adaptar às suas necessidades e fornecer o suporte necessário durante a direção.
- Análise de dados e aprendizado de máquina: O estudo também se concentra no emprego de técnicas de aprendizado de máquina para analisar os dados coletados, permitindo a classificação e a previsão de MCI em tempo real, o que pode levar ao desenvolvimento de sistemas de assistência de direção adaptáveis.

III. TECNOLOGIAS UTILIZADAS

Várias tecnologias avançadas para auxiliar e monitorar esses motoristas foram utilizadas nesse estudo:

- 1) Sensores no veículo: A pesquisa incorpora vários sensores, incluindo câmeras e acelerômetros, para coletar dados sobre comportamento de direção, dinâmica do veículo e interações do motorista. Esses sensores ajudam a monitorar condições e comportamentos de direção em tempo real.
- 2) Dados telemáticos: Sistemas telemáticos são empregados para coletar e analisar dados relacionados ao desempenho do veículo e comportamento do motorista. Esses dados podem fornecer insights sobre padrões de direção e potenciais comprometimentos cognitivos.
- 3) Técnicas de aprendizado de máquina: O estudo utiliza algoritmos de aprendizado de máquina para analisar os dados coletados. Essas técnicas permitem a classificação e a previsão de MCI ao reconhecer padrões anômalos no comportamento de direção, o que pode indicar declínio cognitivo.
- 4) Sistemas de monitoramento em tempo real: A integração dessas tecnologias permite o monitoramento em tempo real do desempenho de direção, possibilitando intervenções oportunas e assistência adaptativa à direção. Isso pode incluir alertas ou modificações em sistemas de assistência à direção com base no estado cognitivo do motorista.
- 5) Ferramentas de análise de dados: Ferramentas avançadas de análise de dados são utilizadas para processar grandes quantidades de dados coletados dos sensores e sistemas telemáticos. Isso facilita a identificação de mudanças sutis no comportamento de direção que podem estar associadas ao MCI.

No geral, essas tecnologias trabalham juntas para criar um sistema abrangente que visa aumentar a segurança e a independência de motoristas.

IV. O HARDWARE

Os autores desenvolveram um sistema de detecção no veículo, que inclui unidades de detecção telemática e de

visão, para coletar conjuntos de dados relacionados ao comportamento do motorista. O sistema foi instalado e ficou nos veículos dos participantes por três anos para coletar fluxos de dados longitudinais, para capturar mudanças no comportamento de direção ao longo do tempo. O estudo de cinco anos foi conduzido na Florida Atlantic University e na University of Central Florida (UCF) para motoristas idosos com ou sem MCI e com carteira de motorista válida. O estudo envolveu 236 participantes no terceiro ano para avaliar o status cognitivo e comportamental dos motoristas.

A. Unidades Telemáticas programáveis - TMUs

TMUs são dispositivos programáveis e de código aberto que suportam a robusta expansibilidade do sistema de hardware e software, permitindo o desenvolvimento de TMUs personalizadas para ajustar e modificar os parâmetros de detecção (por exemplo, algoritmos de coleta de dados e frequências de amostragem). Nesse estudo foram utilizados TMUs com Raspberry Pi4. Cada TMU compreende um sensor GPS, uma unidade de medição inercial (IMU), um conector OBD, um modem celular 4G/LTE, um cartão SD e uma unidade flash USB. Giroscópios triaxiais são adicionados às TMUs para capturar a velocidade angular, para monitorar continuamente os níveis de tensão da porta. Os dados do veículo podem ser coletados através do Controller Area Network (CAN). Dentro de um grupo de veículos, o CAN permite que a unidade de controle do motor (ECU), unidade de controle da transmissão, unidade de controle do sistema de freio, unidade de controle do sistema de direção e outros troquem informações de forma rápida e eficiente, fornecendo acesso aos dados de status do veículo, como leituras de sensores, sinais de controle e informações de diagnóstico. Uma das maneiras mais comuns de obter dados do barramento CAN é usando conectores On-Board Diagnostics (OBD). Os dados OBD disponíveis incluem RPM do motor, velocidade do veículo e status do sistema de combustível. Dados adicionais podem ser coletado, como GPS e módulos de unidade de medição inercial (IMU).

V. DADOS ANALISADOS

Os principais aspectos do processo de análise de dados, conforme descrito no estudo foram:

Coleta e pré-processamento de dados: O estudo coletou um conjunto de dados substancial consistindo de 7.794 amostras de dados em 19 variáveis independentes relacionadas ao comportamento de direção. Esses dados foram coletados dos sensores no veículo e sistemas telemáticos. Antes da análise, os dados passaram por pré-processamento para garantir sua qualidade e confiabilidade. Isso incluiu técnicas normalização de quantil, para ajustar a distribuição de dados e métodos para lidar com outliers por meio de flooring (para valores mais baixos) e capping (para valores mais altos).

Índices de comportamento do motorista (DBIs): A análise se concentrou em derivar índices de comportamento do motorista (DBIs) dos dados coletados. Esses índices são projetados para refletir vários aspectos do desempenho de direção, incluindo velocidade, aceleração, padrões de frenagem e

outras dinâmicas de direção. Ao analisar esses índices, os pesquisadores buscaram identificar padrões e mudanças no comportamento de direção que poderiam ser indicativos de declínio cognitivo.

Técnicas de aprendizado de máquina: O estudo empregou algoritmos de aprendizado de máquina, especificamente o método Random Forests, para fins de classificação e previsão. Random Forests é uma técnica de aprendizado de conjunto que constrói várias árvores de decisão com base em subconjuntos aleatórios dos dados de treinamento. Essa abordagem aprimora o desempenho e a precisão do modelo na previsão da presença ou ausência de MCI com base nos DBIs e outros recursos de entrada.

Treinamento e validação do modelo: Os modelos de aprendizado de máquina foram treinados usando os dados pré-processados, com os DBIs servindo como variáveis de entrada. Os modelos foram validados para avaliar suas capacidades preditivas, com foco em sua capacidade de classificar com precisão os motoristas como tendo MCI ou não. O estudo relatou altas taxas de precisão, indicando que os modelos poderiam distinguir efetivamente entre diferentes estados cognitivos com base no comportamento de direção.

Análise de Importância de Recursos: Um aspecto importante da análise de dados foi a avaliação da importância das características dentro dos modelos de aprendizado de máquina. Essa análise ajudou a identificar quais comportamentos e características de direção eram mais preditivos de MCI. Entender a importância de várias características permite que os pesquisadores se concentrem nos indicadores mais relevantes de declínio cognitivo, aprimorando a interpretabilidade e a aplicação prática do modelo.

Análise Longitudinal: A natureza longitudinal da coleta de dados permitiu o exame de mudanças no comportamento de direção ao longo do tempo. Ao analisar como os DBIs evoluem, os pesquisadores podem obter insights sobre a progressão do comprometimento cognitivo e seu impacto no desempenho de direção. Essa análise temporal é vital para entender a dinâmica do declínio cognitivo e suas implicações para a segurança no trânsito.

Potencial de Monitoramento em Tempo Real: As descobertas da análise de dados sugerem que o sistema de detecção em veículo desenvolvido pode facilitar o monitoramento em tempo real do comportamento de direção. Ao analisar continuamente os DBIs e outros dados relevantes, o sistema pode fornecer feedback ou alertas imediatos aos motoristas, ajudando a garantir a segurança e a intervenção imediata se o declínio cognitivo for detectado.

VI. OUTRAS TECNOLOGIAS EM REDES VEICULARES - CÂMERAS

Câmeras veiculares funcionam como dispositivos de captura de imagens e vídeos em tempo real que são integrados ao sistema de controle do veículo ou à infraestrutura viária. Essas câmeras podem ser instaladas em diferentes partes do veículo, como o para-brisa, laterais e traseira, para cobrir diversas áreas de interesse. A sua função principal é coletar dados

visuais do ambiente externo e, por meio de processamento de imagem, identificar informações úteis para a condução segura e eficiente. O funcionamento básico de câmeras em redes veiculares envolve:

- **Captura de Imagem:** A câmera captura imagens ou vídeos em tempo real enquanto o veículo está em movimento.
- **Processamento de Imagem:** Os dados capturados são enviados para uma unidade de processamento, onde algoritmos de visão computacional analisam as informações. Esses algoritmos podem identificar objetos, pedestres, sinalizações e outros veículos.
- **Integração com Outros Sensores:** Em redes veiculares, as câmeras trabalham em conjunto com outros sensores, como radares, sensores de proximidade, LiDARs, e GPS, para fornecer uma visão mais completa do ambiente.
- **Transmissão de Dados:** Em veículos conectados ou autônomos, os dados das câmeras podem ser compartilhados via redes de comunicação veicular (V2X - Vehicle-Everything) com outros veículos, infraestrutura de trânsito, e centros de controle de tráfego.
- **Ação com Base em Dados: A partir das informações processadas, o sistema pode tomar decisões automáticas, como acionar freios, ajustar a velocidade ou fornecer alertas ao motorista.**

A. Benefícios das Câmeras em Redes Veiculares

- 1) **Segurança:** A capacidade de detecção de obstáculos em tempo real ajuda a prevenir colisões, detectar pedestres e garantir uma condução mais segura, especialmente em cenários de baixa visibilidade ou à noite.
- 2) **Auxílio ao Motorista:** Sistemas avançados de assistência ao motorista (ADAS) utilizam câmeras para fornecer alertas sobre mudanças de faixa, aproximação de outros veículos, entre outros.
- 3) **Condução Autônoma:** Câmeras são componentes essenciais para veículos autônomos, sendo responsáveis por detectar objetos, sinalização de trânsito e mudanças no ambiente ao redor do veículo.
- 4) **Gestão de Tráfego:** Em redes veiculares conectadas, as câmeras podem capturar dados sobre o tráfego em tempo real e transmitir essas informações para sistemas de gerenciamento, otimizando o fluxo de veículos nas cidades.

B. Estudo 3: A Dual-Cameras-Based Driver Gaze Mapping System With an Application on Non-Driving Activities Monitoring

No estudo apresentado por [21], a metodologia é estruturada em quatro etapas principais: aquisição de vídeos, extração de características, mapeamento do olhar e visualização de mapa de calor. A primeira etapa envolve a captura de vídeos através de duas câmeras. A primeira câmera, posicionada em frente ao motorista, coleta características faciais, como o olhar e o movimento da cabeça. Já a segunda câmera, localizada acima do motorista, é utilizada para simular a visão do condutor.

A direção dos olhos, juntamente com outros parâmetros, como a localização e a orientação do rosto, são extraídos da primeira câmera. Esses parâmetros são então usados para modelar e mapear características relevantes que ajudam a estimar a saída desejada, enquanto a segunda câmera mapeia a localização exata do olhar do motorista.

A calibração do modelo de mapeamento visa estabelecer uma correlação entre as características faciais capturadas pela primeira câmera e as localizações do olhar obtidas pelas imagens da segunda câmera. Durante o processo de calibração (ou treinamento), as localizações do olhar nas imagens da segunda câmera são conhecidas por meio de marcadores colocados no interior do veículo. Adicionalmente, um ruído gaussiano com um sigma predefinido é aplicado nas localizações dos marcadores nas imagens da segunda câmera, funcionando como saídas conhecidas nos dados de treinamento.

Do ponto de vista da identificação de sistemas, a adição de ruído à saída desejada contribui para reduzir o overfitting, promovendo uma melhor generalização do modelo e, assim, aprimorando a precisão da análise. Essa abordagem permite capturar variações naturais no comportamento do olhar, tornando o sistema mais robusto e capaz de se adaptar a diferentes condições de direção e cenários.

1) *Aquisição de Vídeo:* O sistema de captura descrito utiliza duas câmeras estrategicamente posicionadas para monitorar o comportamento do motorista. A primeira câmera, localizada na frente do motorista, captura a face e o movimento da cabeça, enquanto a segunda câmera, localizada acima do motorista, simula a visão do condutor. Além disso, dentro do veículo, diversos marcadores estão posicionados em locais de interesse, como o painel de instrumentos, espelhos laterais, espelho retrovisor, para-brisa, display multimídia e volante. Esses locais são fixos e amigáveis para o motorista direcionar o olhar, sendo elementos importantes para a avaliação do comportamento visual.

A primeira câmera opera com uma resolução de 1024x768 pixels e grava a 24 quadros por segundo (FPS), permitindo capturar de maneira detalhada os movimentos faciais e o direcionamento do olhar. A segunda câmera, definida com uma resolução de 1440x1080 pixels, mantém a mesma taxa de quadros, garantindo uma visão precisa da área externa e daquilo que o motorista estaria observando. A combinação dessas duas fontes de dados, junto com os marcadores internos do veículo, proporciona um mapeamento eficaz do olhar e permite analisar com precisão os padrões visuais do condutor ao interagir com os elementos do carro.

2) *Extração de Recursos:* Diversos métodos para rastreamento do olhar e da posição da cabeça foram propostos ao longo do tempo. Dentre as ferramentas de análise facial de código aberto mais amplamente utilizadas, destaca-se o OpenFace, conhecido por seu bom desempenho e robustez na extração de características faciais. O OpenFace é capaz de detectar marcos faciais, realizar o reconhecimento de unidades de ação, estimar a pose da cabeça e calcular a direção do olhar, tornando-o uma ferramenta adequada para análise de comportamentos visuais em motoristas.

No contexto do estudo, propõe-se o uso das informações da cabeça e do olhar para a construção de um mapa de calor do olhar, que permite visualizar os pontos de foco do motorista dentro do veículo. Para isso, os parâmetros selecionados são divididos em duas categorias principais: parâmetros relacionados à pose da cabeça (HRPs, Head-Related Parameters) e parâmetros relacionados ao olhar (GRPs, Gaze-Related Parameters). Os HRP's incluem a posição da cabeça detectada em relação à primeira câmera, que está situada na frente do motorista.

Esses parâmetros são cruciais para modelar a direção do olhar e, em conjunto, construir mapas de calor que identifiquem as áreas mais observadas dentro do veículo, como o painel, espelhos e display multimídia. Essa análise facilita a compreensão de como as alterações cognitivas podem impactar o comportamento visual de motoristas idosos ou com comprometimento cognitivo leve (MCI), possibilitando intervenções voltadas à segurança no trânsito.

3) *Mapeamento de recursos*: Para estabelecer a correspondência entre as características faciais, extraídas com base nas coordenadas da primeira câmera, e o mapeamento do olhar, obtido com base nas coordenadas da segunda câmera, uma abordagem eficaz é o uso do algoritmo de Mínimos Quadrados Ortogonais (OLS). Este método ajusta um modelo linear minimizando os erros ortogonais entre os parâmetros selecionados, proporcionando uma estimativa robusta da relação entre as características faciais e o direcionamento do olhar.

No contexto de identificação de sistemas não lineares, a abordagem OLS é utilizada para avaliar múltiplos modelos candidatos, selecionando aqueles mais eficazes para a construção do modelo final. Para orientar essa seleção, um critério fundamental é a Taxa de Redução de Erro (ERR), que mede a quantidade de variação na resposta do sistema explicada pela inclusão de termos relevantes no modelo. A ERR é expressa em porcentagem, indicando o quanto a precisão do modelo melhora com a adição de determinados parâmetros.

Este algoritmo, além de avaliar o ajuste global do modelo, permite a seleção de características faciais importantes, otimizando a modelagem ao equilibrar a complexidade do modelo e o desempenho da estimativa do olhar. Através dessa técnica, podemos reduzir o impacto de termos desnecessários, evitando o sobreajuste (overfitting) e melhorando a generalização do sistema. Em resumo, o OLS, combinado com a ERR, oferece uma abordagem eficiente para identificar as variáveis mais influentes e construir um modelo robusto para o rastreamento do olhar em sistemas de monitoramento de motoristas.

4) *Visualização do Mapa de Calor*: O mapa de calor é uma abordagem amplamente utilizada para a visualização de dados espaciais, sendo especialmente eficaz na representação da distribuição do olhar de um motorista em um ambiente controlado, como dentro de um veículo. Esse método permite observar onde o motorista está concentrando sua atenção ao longo do tempo, facilitando a análise de padrões de comportamento visual.

O olhar fixo em um determinado momento ou quadro pode ser representado por um círculo definido por três parâmetros principais: a posição do olhar (coordenadas x e y), o raio do círculo e a intensidade da fixação. A distribuição espacial dentro do círculo segue uma distribuição gaussiana, que reflete a probabilidade de onde o olhar está focado. Para este estudo, o raio do círculo foi definido como 40 pixels, uma escolha que foi influenciada pela resolução da segunda câmera (1440x1080 pixels), que simula a visão do motorista.

Além de capturar a fixação do olhar em momentos específicos, o estudo também analisa a trajetória do olhar ao longo do tempo. Isso é feito integrando a distribuição espacial do olhar dentro de uma determinada janela temporal, permitindo visualizar a sequência de pontos focais e entender melhor o comportamento visual dinâmico do motorista. Esse tipo de análise é fundamental para identificar mudanças de atenção ou sinais de comprometimento cognitivo, especialmente em motoristas mais velhos ou com condições cognitivas leves, como o Comprometimento Cognitivo Leve (MCI).

VII. RESULTADOS

Os resultados do estudo sobre detecção no veículo para motoristas mais velhos com comprometimento cognitivo leve (MCI) destacam várias descobertas importantes relacionadas à eficácia das tecnologias e metodologias empregadas:

- **Índices de comportamento do motorista (DBIs)**: A análise de dados no veículo levou à caracterização dos Índices de comportamento do motorista (DBIs), que refletem as funções físicas e cognitivas ao longo do tempo. Esses índices fornecem insights valiosos sobre como o comportamento de direção muda conforme o comprometimento cognitivo progride.
- **Desempenho do modelo de aprendizado de máquina**: O estudo utilizou um modelo de aprendizado de máquina Random Forest para classificar e prever o status de MCI com base em vários recursos de entrada, como idade, número de viagens e variáveis de direção. O modelo demonstrou alta precisão, com métricas de desempenho indicando fortes capacidades preditivas. Por exemplo, o modelo atingiu uma precisão de 0,86 e uma AUC (Área sob a curva) de 0,95 quando todas as variáveis foram consideradas.
- **Importância da variável**: Os resultados indicaram que certas variáveis, como o número de viagens e comportamentos de direção específicos, foram preditores significativos de MCI. A análise mostrou que motoristas mais velhos com MCI exibiram padrões de direção distintos em comparação com seus colegas sem MCI, o que poderia ser aproveitado para detecção e intervenção precoces.
- **Coleta de dados longitudinais**: O design do estudo incluiu coleta de dados longitudinais ao longo de três anos, permitindo a observação de mudanças no comportamento de direção ao longo do tempo. Essa abordagem forneceu uma visão abrangente de como o declínio cognitivo afeta as habilidades de direção, reforçando a importância do monitoramento contínuo.

- Potencial de monitoramento em tempo real: As descobertas sugerem que o sistema de detecção em veículo tem o potencial de facilitar o monitoramento e a intervenção em tempo real para motoristas mais velhos. Ao identificar mudanças no comportamento de direção, indicativas de declínio cognitivo, o sistema pode fornecer alertas oportunos ou assistência adaptativa para aumentar a segurança.
- Implicações para a segurança rodoviária: No geral, os resultados ressaltam o potencial das tecnologias de detecção no veículo combinadas com o aprendizado de máquina para melhorar a segurança rodoviária para motoristas mais velhos com MCI. A identificação precoce de deficiências cognitivas por meio da análise do comportamento de direção pode levar a intervenções oportunas, apoiando, em última análise, a independência e a mobilidade dessa população.

Já o estudo [21] apresenta uma metodologia completa e inovadora para o rastreamento visual de motoristas, utilizando um sistema de captura de vídeo duplo para mapear e analisar o comportamento visual. A combinação de técnicas avançadas de extração de características, mapeamento de dados e visualização de mapas de calor permite uma análise detalhada da atenção do motorista, crucial para intervenções voltadas à segurança no trânsito. O uso de algoritmos como o OLS e a ERR otimiza o modelo, garantindo a precisão e a generalização, elementos essenciais em sistemas de monitoramento de motoristas. Este estudo contribui significativamente para o campo de segurança automotiva, oferecendo ferramentas úteis para avaliar e, potencialmente, mitigar riscos associados a comprometimentos cognitivos e distração visual ao dirigir.

VIII. PRODUTOS NO MERCADO

Já existem carros equipados com sensores e tecnologias projetadas para detectar mudanças na cognição, atenção e comportamento de direção, especialmente em motoristas idosos. Alguns exemplos são citados nas sessões a seguir [4]–[11]:

A. Sistemas de monitoramento do motorista (DMS)

Monitoramento cognitivo: Carros avançados têm sistemas que monitoram sinais de fadiga cognitiva, distração ou comprometimento. Eles podem rastrear o movimento dos olhos, taxa de piscadas, posição da cabeça e até mesmo expressões faciais para detectar sinais de sonolência ou desatenção. Alguns exemplos de assistência de atenção são o sistema **Mercedes-Benz's Attention Assist** ou **Nissan's Driver Attention Alert** que rastreiam padrões de direção e avisam os motoristas quando irregularidades sugerem fadiga ou lapsos de concentração. Já o **Toyota's Guardian System** usa sensores para ajudar a monitorar mudanças cognitivas e físicas e intervir quando necessário. Ele combina tecnologia autônoma com assistência ao motorista para aumentar a segurança.

B. Sensores biométricos

Sensores biométricos em carros são uma tecnologia emergente que visa melhorar a segurança e o conforto dos motoristas. Eles monitoram sinais vitais e características físicas para detectar cansaço, estresse ou até mesmo condições médicas emergenciais. As marcas de carros que já possuem essa tecnologia são:

- Mercedes-Benz S-Class: A Mercedes-Benz está na vanguarda da tecnologia de sensores em veículos. O modelo S-Class possui um sistema que pode rastrear a frequência cardíaca e monitorar sinais de fadiga por meio de câmeras e sensores de movimento. O Mercedes Attention Assist também avisa os motoristas quando detecta sonolência ou desatenção.
- BMW Série 7: Este veículo utiliza câmeras infravermelhas para rastrear os olhos e a face do motorista, detectando sinais de fadiga e falta de atenção.
- Ford's In-Car Health Monitoring System: A Ford tem investido em sensores incorporados ao volante e aos assentos que podem monitorar a frequência cardíaca do motorista. Esses sistemas estão sendo testados para ajudar a detectar problemas de saúde, como sinais de ataque cardíaco ou níveis elevados de estresse.
- Tesla: Embora os carros da Tesla, como o Model S e o Model 3, não tenham sensores biométricos dedicados ainda, eles usam sistemas de monitoramento baseados em câmeras e inteligência artificial para observar a atenção do motorista (como a observação de olhos) para garantir que o motorista esteja alerta enquanto usa o Autopilot.
- Volvo EX90: A Volvo anunciou que o novo SUV elétrico EX90 usará câmeras e sensores para monitorar a atenção do motorista e poderá detectar sinais de cansaço ou distração. Embora não seja um sensor biométrico completo, ele visa melhorar a segurança com base em como o motorista está fisicamente se comportando.
- Nissan Intelligent Mobility: A Nissan está desenvolvendo tecnologias que monitoram a saúde e o bem-estar dos motoristas, incluindo sensores que podem detectar fadiga ou distração. Eles estão pesquisando também a integração de tecnologias biométricas, como detecção de estresse através de sinais vitais.
- Toyota Concept-i: Um carro conceito que usa inteligência artificial para monitorar o humor do motorista, incluindo sensores que podem ler os sinais vitais, como frequência cardíaca e respiração. O carro adapta suas respostas ao estado emocional e físico do motorista.
- Hyundai Health + Mobility Cockpit: Um sistema conceitual que usa sensores biométricos para medir a condição do motorista, incluindo estresse e fadiga, e ajustar o ambiente do veículo (como temperatura e música) para melhorar o conforto e o bem-estar.

Muitos projetos estão ainda em fase de pesquisa e desenvolvimento, mas várias montadoras já estão implementando versões iniciais desses recursos.

C. IA e análise preditiva

[12]–[20] Carros integrados com sistemas de IA podem coletar dados de longo prazo sobre os hábitos de um motorista e detectar desvios que podem indicar problemas cognitivos ou os estágios iniciais de demência. Empresas que estão desenvolvendo tecnologias de Inteligência Artificial (IA) e análise preditiva para carros estão principalmente concentradas em áreas como condução autônoma, monitoramento do comportamento do motorista, e manutenção preditiva. Aqui estão algumas das principais empresas que lideram essas inovações:

- Tesla: Tesla usa IA avançada para o seu sistema de Autopilot e Full Self-Driving (FSD), permitindo que os carros façam previsões sobre o tráfego, comportamento de outros motoristas e ambientes rodoviários.
- Waymo (subsidiária da Alphabet/Google): usa IA e machine learning para prever as ações de pedestres, ciclistas e outros veículos, aprimorando sua frota de carros autônomos.
- Mobileye (Intel): A Mobileye desenvolve sistemas baseados em câmeras que usam IA para identificar obstáculos e prever comportamentos em tempo real, ajudando na prevenção de acidentes.
- NVIDIA: A NVIDIA fornece plataformas de hardware e software de IA, como o NVIDIA DRIVE, que habilita capacidades de análise preditiva e aprendizado de máquina para direção autônoma.
- Aptiv: Aptiv usa IA para sensores avançados e software de previsão de comportamentos no trânsito, além de soluções de manutenção preditiva para prever falhas em componentes.
- Zoox (subsidiária da Amazon): Zoox desenvolve carros autônomos que utilizam IA para prever o comportamento de outros veículos e pedestres em ambientes urbanos.
- Nauto: A Nauto oferece uma plataforma de IA que analisa o comportamento do motorista em tempo real e usa análise preditiva para alertar sobre possíveis acidentes antes que eles ocorram.
- Aurora Innovation: desenvolve sistemas de IA para veículos autônomos, incluindo tecnologias que preveem o comportamento de outros usuários da estrada e ajustam o comportamento do veículo.
- Arity: analisa dados telemáticos e comportamento dos motoristas para fazer previsões sobre segurança e riscos, ajudando seguradoras a personalizar suas ofertas.
- Valeo: desenvolve soluções de IA que melhoram a segurança por meio de sensores que analisam o ambiente e fazem previsões sobre eventos rodoviários.

D. Monitoramento de saúde no veículo

A **Ford** tem trabalhado em um assento com sensores incorporados que medem a frequência cardíaca, o que pode detectar anomalias que podem sinalizar um comprometimento cognitivo ou físico.

E. Câmeras externas e sistemas de radar

Alguns carros, como aqueles com Autopilot da **Tesla** ou IntelliSafe da **Volvo**, usam câmeras externas e sistemas de radar para monitorar o comportamento do motorista e auxiliar na manutenção de faixa, controle de cruzeiro adaptativo e frenagem automática, fornecendo suporte adicional a motoristas mais velhos cujos reflexos podem estar diminuindo.

F. Sistemas colaborativos

O sistema Invisible-to-Visible (I2V) **Nissan** conecta sensores no carro com dados da nuvem para prever o que está por vir (como pontos cegos ou cruzamentos perigosos) enquanto monitora a conscientização e a prontidão do motorista, ajudando motoristas mais velhos, dando-lhes mais tempo para reagir.

Esses sistemas ajudam a compensar o declínio natural nas habilidades cognitivas e motoras que podem ocorrer com o envelhecimento, tornando a direção mais segura para adultos mais velhos, mantendo sua independência.

REFERENCES

- [1] United Nations Department of Economic and Social Affairs (UN DESA). "World Population Prospects reports" <https://population.un.org/wpp/>
- [2] Tappen, Ruth, et al. "Study protocol for "In-vehicle sensors to detect changes in cognition of older drivers"." *BMC geriatrics* 23.1 (2023): 854.
- [3] Moshfeghi, Sonia, et al. "In-vehicle sensing and data analysis for older drivers with mild cognitive impairment." 2023 IEEE 20th International Conference on Smart Communities: Improving Quality of Life using AI, Robotics and IoT (HONET). IEEE, 2023.
- [4] Mercedes-Benz. "Mercedes-Benz Official Website." *Mercedes-Benz*, 2024, <https://www.mercedes-benz.com>. Accessed 16 Oct. 2024.
- [5] BMW. "BMW Official Website." *BMW*, 2024, <https://www.bmw.com>. Accessed 16 Oct. 2024.
- [6] Ford. "Ford Official Website." *Ford*, 2024, <https://www.ford.com>. Accessed 16 Oct. 2024.
- [7] Tesla. "Tesla Official Website." *Tesla*, 2024, <https://www.tesla.com>. Accessed 16 Oct. 2024.
- [8] Volvo. "Volvo Cars Official Website." *Volvo Cars*, 2024, <https://www.volvocars.com>. Accessed 16 Oct. 2024.
- [9] Nissan. "Nissan Global Official Website." *Nissan*, 2024, <https://www.nissan-global.com>. Accessed 16 Oct. 2024.
- [10] Toyota. "Toyota Global Official Website." *Toyota*, 2024, <https://www.toyota-global.com>. Accessed 16 Oct. 2024.
- [11] Hyundai. "Hyundai Official Website." *Hyundai*, 2024, <https://www.hyundai.com>. Accessed 16 Oct. 2024.
- [12] Waymo. "Waymo Official Website". Waymo, 2024, <https://waymo.com>. Accessed 16 Oct. 2024.
- [13] Mobileye. "Mobileye Official Website". Mobileye, 2024, <https://www.mobileye.com>. Accessed 16 Oct. 2024.
- [14] NVIDIA. "NVIDIA Official Website". NVIDIA, 2024, <https://www.nvidia.com>. Accessed 16 Oct. 2024.
- [15] Aptiv. "Aptiv Official Website". Aptiv, 2024, <https://www.aptiv.com>. Accessed 16 Oct. 2024.
- [16] Zoox. "Zoox Official Website". Zoox, 2024, <https://zoox.com>. Accessed 16 Oct. 2024.
- [17] Nauto. "Nauto Official Website". Nauto, 2024, <https://www.nauto.com>. Accessed 16 Oct. 2024.
- [18] Aurora Innovation. "Aurora Official Website". Aurora, 2024, <https://aurora.tech>. Accessed 16 Oct. 2024.
- [19] Arity. "Arity Official Website". Arity, 2024, <https://www.arity.com>. Accessed 16 Oct. 2024.
- [20] Valeo. "Valeo Official Website". Valeo, 2024, <https://www.valeo.com>. Accessed 16 Oct. 2024.

- [21] L. Yang, K. Dong, A. J. Dmitruk, J. Brighton and Y. Zhao, "A Dual-Cameras-Based Driver Gaze Mapping System With an Application on Non-Driving Activities Monitoring," in *IEEE Transactions on Intelligent Transportation Systems*, vol. 21, no. 10, pp. 4318-4327, Oct. 2020, doi: 10.1109/TITS.2019.2939676.